

Segmentación de Casos Migratorios al Ingreso con K-Means sobre un Servidor MCP

Araceli Castillo

Maestría en Inteligencia Artificial, Atlantis University

MAI 540: Machine Learning

Prof. Kevin A. García Gallardo

6 de octubre de 2026

Segmentación de Casos Migratorios al Ingreso con K-Means sobre un Servidor MCP

Esta tarea extiende el servidor del Protocolo de Contexto de Modelos (MCP) de la Tarea 5.1 con una tool de segmentación, `segmentar_kmeans`, construida con el mismo patrón: la lógica en `kmeans_utils.py` y el decorador en `mcp_server.py`. Se aplicó a un problema de mi sector: agrupar al ingreso los casos de detención migratoria para que el equipo de case management planifique su trabajo. La herramienta no decide nada sobre la persona.

Datos y Herramienta

Se usaron 2,854 casos sintéticos de la Tarea 4.2, los que no tienen faltantes, con ocho variables que se conocen al ingresar el caso: edad, meses en EE. UU., número de dependientes y cinco de sí/no (detenido, representación legal, intérprete, antecedentes penales y solicitud de fianza). Las variables que solo se conocen al cerrar el caso, como los días hasta la resolución, quedaron fuera de la carpeta que el servidor puede leer: no forman los grupos y solo se usan después para describirlos. La tool estandariza las variables, corre K-Means con 50 reinicios y semilla 42, y devuelve las etiquetas, el tamaño de cada grupo, la inercia y el coeficiente de silueta (Pedregosa et al., 2011). Se verificó en el MCP Inspector, que además rechaza un k fuera del rango de 2 a 10 y los nombres de archivo que intentan salir de la carpeta permitida.

Elección del Número de Grupos

El criterio se fijó en el script de análisis antes de describir los grupos: el codo, entendido como el último k en el que agregar un grupo todavía reduce la inercia en al menos 10 %, confirmado por un máximo local de la silueta (Rousseeuw, 1987). Ese k es 5 (Tabla 1 y Figura 1). El quinto grupo reduce la inercia en 10.7 % y el sexto solo en 8.0 %. La silueta de k = 5 (0.233) es mayor que la de k = 4 (0.221) y la de k = 6 (0.229). La silueta vuelve a subir en k = 9 (0.261), pero ahí cada grupo nuevo aporta menos de 6 %, el grupo más pequeño tiene 145 casos

y la partición es menos reproducible, así que es demasiado fina para planificar el trabajo de un equipo.

Dos resultados limitan la lectura. Primero, la silueta es baja en todos los k : los grupos se traslapan y son cortes útiles, no tipos de casos separados por naturaleza. Segundo, con 10 reinicios K-Means a veces se quedaba en un óptimo local peor y otra semilla producía otra partición (índice de Rand ajustado de 0.77 en $k = 5$; Hubert y Arabie, 1985). Con 50 reinicios todas las semillas coinciden (0.998), y ese valor quedó fijo en la herramienta.

Visualización con Análisis de Componentes Principales

Los casos se proyectaron en dos componentes con la tool ejecutar_pca de la Tarea 5.1: las coordenadas son los datos escalados multiplicados por las cargas que devuelve (Figura 2). El plano conserva 36.3 % de la varianza (20.1 % y 16.2 %). Es poco porque cinco de las ocho variables son de sí/no y están poco correlacionadas (Géron, 2022): grupos que en el plano se ven mezclados, como los detenidos con y sin fianza, están separados en las ocho dimensiones.

Interpretación de los Grupos

La Tabla 2 describe cada grupo por lo que lo distingue y propone una acción para el equipo. Los no detenidos tienen los casos más largos y necesitan seguimiento a distancia; los detenidos que pidieron fianza tienen la menor tasa de representación legal; los detenidos sin fianza siguen procesos rápidos que no dejan margen para corregir; las personas con antecedentes penales requieren preparación legal temprana, y las familias con dependientes conviene llevarlas como una sola unidad. La necesidad de intérprete (28 % a 36 %) aparece en todos los grupos por igual, así que no los distingue: hay que planificarla para todos.

Limitaciones

Los datos son sintéticos: el método se puede trasladar, pero los porcentajes no describen casos reales. Los grupos se traslapan y el plano de dos componentes solo muestra un tercio de la varianza. K-Means trata igual las variables de sí/no y las continuas una vez escaladas; un método para datos mixtos podría separar mejor. Y las acciones son para organizar el trabajo, nunca para decidir la detención, la fianza ni el fondo de un caso.


Referencias

- Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3.^a ed.). O'Reilly Media.
- Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1), 193–218.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.

Tabla 1*Inercia, Silueta y Reproducibilidad para k de 2 a 10*

k	Reducción de inercia	Silueta	ARI entre semillas	Grupo más pequeño
2	15.9 %	0.181	1.000	895
3	14.1 %	0.216	1.000	329
4	12.8 %	0.221	1.000	329
5	10.7 %	0.233	0.998	265
6	8.0 %	0.229	0.997	249
7	6.4 %	0.231	0.974	165
8	6.1 %	0.241	0.946	158
9	5.6 %	0.261	0.918	145
10	5.5 %	0.256	0.833	133


Nota. El k elegido es 5. La reducción de inercia es la que aporta el grupo k frente a k – 1. ARI: índice de Rand ajustado promedio entre 10 semillas, con 50 reinicios cada una.

Figura 1*Codo, Silueta y Reproducibilidad Según el Número de Grupos*

Nota. El punto naranja marca k = 5.

Figura 2

Casos Proyectados en los Dos Primeros Componentes Principales, por Grupo



Nota. El plano conserva 36.3 % de la varianza. Las franjas verticales vienen de las variables de sí/no.

Tabla 2

Qué Caracteriza a Cada Grupo y Acción Propuesta

Grupo	Casos	Qué lo caracteriza	Acción propuesta
No detenidos	753	En libertad; los casos más largos (mediana de 326 días, 5.3 aplazamientos); 55 % asilo; 59 % con abogado.	Seguimiento a distancia con calendario fijo: recordatorio de cada audiencia y verificación mensual de domicilio.
Detenidos que pidieron fianza	587	Todos detenidos y con solicitud de fianza; solo 27 % con abogado, la tasa más baja.	Referir a servicios legales gratuitos en la primera semana y preparar los documentos para la audiencia de fianza.
Detenidos sin fianza (vía rápida)	944	El grupo más grande y más rápido: mediana de 57 días; 54 % miedo creíble o reinstalación.	Revisión el primer día: orientación legal, intérprete confirmado y documentos completos.
Con antecedentes penales	305	Todos con antecedentes; mayores (31 años en promedio); 89 % detenidos; mediana de 106 días.	Asignar case managers con experiencia y pedir al ingreso los registros judiciales.
Familias con dependientes	265	2.7 dependientes en promedio; 41 % no detenidos; casos largos (mediana de 219 días).	Llevar el expediente familiar como una unidad: audiencias coordinadas y servicios para menores.

Nota. Los días hasta la resolución y los aplazamientos no se usaron para formar los grupos; solo para describirlos.