

Segmentación de Casos Migratorios al Ingreso con K-Means

Araceli Castillo · MAI 540: Machine Learning · Prof. Kevin A. García Gallardo · Atlantis University · 6 de octubre de 2026

1. Datos y herramienta

Se segmentaron 2,854 casos sintéticos de la Tarea 4.2 (los que no tienen faltantes) con ocho variables que se conocen al ingresar el caso: edad, meses en EE. UU., número de dependientes y cinco de sí/no (detenido, representación legal, intérprete, antecedentes penales y solicitud de fianza). Las que solo se conocen al cerrarlo (días hasta la resolución, aplazamientos) no forman los grupos ni están al alcance del servidor; se usan después, solo para describirlos. La segmentación la hace la tool `segmentar_kmeans` del servidor MCP de la Tarea 5.1, sobre variables estandarizadas.

2. Elección de k

El criterio se fijó antes de describir los grupos (`analisis/segmentacion.py`): el codo, entendido como el último k en el que agregar un grupo todavía reduce la inercia en al menos 10 %, confirmado por un máximo local de la silueta. Ese k es 5: el quinto grupo reduce la inercia en 10.7 % y el sexto solo en 8.0 %, y la silueta de k = 5 (0.233) es mayor que la de k = 4 (0.221) y la de k = 6 (0.229). La silueta vuelve a subir en k = 9 (0.261), pero ahí cada grupo nuevo aporta menos de 6 %, el más pequeño tiene 145 casos y la partición es menos reproducible (0.918): demasiado fina para planificar el trabajo de un equipo.


Tabla 1

Inercia, silueta y reproducibilidad para k de 2 a 10 (k elegido resaltado)

k	Reducción de inercia al agregar el grupo	Silueta	Reproducibilidad (ARI, 10 semillas)	Grupo más pequeño
2	15.9 %	0.181	1.000	895
3	14.1 %	0.216	1.000	329
4	12.8 %	0.221	1.000	329
5	10.7 %	0.233	0.998	265
6	8.0 %	0.229	0.997	249
7	6.4 %	0.231	0.974	165
8	6.1 %	0.241	0.946	158
9	5.6 %	0.261	0.918	145
10	5.5 %	0.256	0.833	133

Figura 1

Codo, silueta y reproducibilidad según el número de grupos




Dos cosas que hay que decir. La silueta es baja en todos los k (0.18 a 0.26): los grupos se traslapan; son cortes útiles para organizar el trabajo, no tipos de casos naturalmente separados. Y la reproducibilidad no venía sola: con 10 reinicios, K-Means a veces se quedaba en un óptimo local peor y otra semilla daba otra partición (ARI de 0.77 en k = 5). Con 50 reinicios todas las semillas coinciden (0.998), y ese valor quedó fijo en `kmeans_utils.py`.

3. Visualización con PCA

Los casos se proyectaron en dos componentes con la tool ejecutar_pca de la Tarea 5.1: las coordenadas son los datos escalados por las cargas que devuelve. El plano conserva 36.3 % de la varianza (20.1 % el primer componente y 16.2 % el segundo). Es poco porque cinco de las ocho variables son de sí/no y están poco correlacionadas, así que dos componentes no las resumen: grupos que en el plano se ven mezclados, como los detenidos sin fianza y los que pidieron fianza, están separados en las ocho dimensiones. Las franjas verticales vienen de esas variables de sí/no.

Figura 2

Casos proyectados en los dos primeros componentes, coloreados por grupo de K-Means



4. Interpretación de cada grupo y acción propuesta

Los nombres describen lo que distingue a cada grupo en los datos (Tabla 2). La necesidad de intérprete (28 % a 36 %) aparece en todos por igual, así que no sirve para distinguirlos: hay que planificarla para todos. Las acciones son para organizar el trabajo del equipo de case management; ninguna decide nada sobre la persona, su detención, su fianza ni el fondo de su caso. Los datos son sintéticos: el método se puede trasladar, pero los porcentajes no describen casos reales.

Tabla 2*Qué caracteriza a cada grupo y qué acción podría tomar la organización*

Grupo	Casos	Qué lo caracteriza	Acción que podría tomar el equipo
No detenidos	753	Personas en libertad cuyo caso es el más largo (mediana de 326 días y 5.3 aplazamientos en promedio); más de la mitad son asilo y 59 % ya tiene abogado.	Seguimiento a distancia con calendario fijo: recordatorio de cada audiencia y verificación de domicilio cada mes, para que un caso de casi un año no se pierda por una ausencia.
Detenidos que pidieron fianza	587	Todos detenidos y todos solicitaron fianza, pero solo 27 % tiene abogado, la tasa más baja de los cinco grupos.	Referirlos a servicios legales gratuitos en la primera semana y preparar con ellos los documentos para la audiencia de fianza.
Detenidos sin fianza (vía rápida)	944	El grupo más grande y más rápido: mediana de 57 días, y 54 % son miedo creíble o reinstalación, procesos con plazos cortos.	Revisión el primer día: orientación legal, intérprete confirmado y documentos completos, porque no hay margen para corregir después.
Con antecedentes penales	305	Todos con antecedentes, mayores que el resto (31 años en promedio) y casi todos detenidos (89 %); mediana de 106 días.	Asignarlos a case managers con experiencia y pedir al ingreso los registros judiciales que el abogado necesitará.
Familias con dependientes	265	2.7 dependientes en promedio y 41 % no detenidos; casos largos (mediana de 219 días), la mitad de asilo.	Llevar el expediente familiar como una sola unidad: audiencias coordinadas y enlace con servicios para menores.